Ajout d’une nouvelle source de données Google Sheets

Voici une série d’exercices sur l’ajout d'une nouvelle source de données :

Exercice 1

1. Récupérer le fichier CSV [MAPPING] Responsables des territoires dans les ressources.
2. Importer ce fichier CSV dans une feuille Google Sheets.
3. Configurer un connecteur Fivetran pour envoyer les données de ce CSV vers notre dataset (ou schéma) google_sheets dans BigQuery.
4. Suivre les instructions fournies par Fivetran dans le bandeau gris, étape par étape, en utilisant l'authentification par service_account (appelez la table finale : account_manager_region_mapping).

Ce CSV contient des informations cruciales pour l’entreprise, à savoir le mapping des account managers responsables des territoires. Cette dimension est fréquemment utilisée dans les tableaux de bord, car elle permet aux responsables de filtrer par leur nom et ainsi visualiser uniquement les informations qui les concernent.

DataBird 2024 ©copyright

La Google Sheet est choisie comme source de données car elle offre une flexibilité pour être facilement modifiée par les équipes métiers.
Nous avons besoin que les données soient mises à jour une fois par jour.

Ajoutez la table Google Sheet à notre diagramme entité-relation du module précédent, en précisant les clés de jointure.

Exercice 2

Modélisation des données brutes de GA4

Partie 1 : On transforme les données brutes de GA4

Il est possible de créer des custom report dans Fivetran avec GA4, mais de nombreuses entreprises préfèrent traiter elles-mêmes les données brutes de GA4 car cela leur offre une plus grande flexibilité dans le calcul des métriques.

GA4 permet également d'exporter directement ces données brutes vers BigQuery (cependant, il est nécessaire de disposer d'un compte Google Analytics 4 connectés à un site web).

Dans cet exercice, nous allons utiliser un échantillon de vraies données brutes de GA4 afin de nous entraîner à les manipuler. Suivez les étapes suivantes :

- Enregistrer dans une table BigQuery un sample de vraies données brutes de GA4, pour cela
  - Tourner cette query dans BigQuery
  - select * from bigquery-public-data.ga4_obfuscated_sample_ecommerce.events_20210131
  - Cliquer sur Enregistrer les résultats > Table BigQuery

DataBird 2024 ©copyright

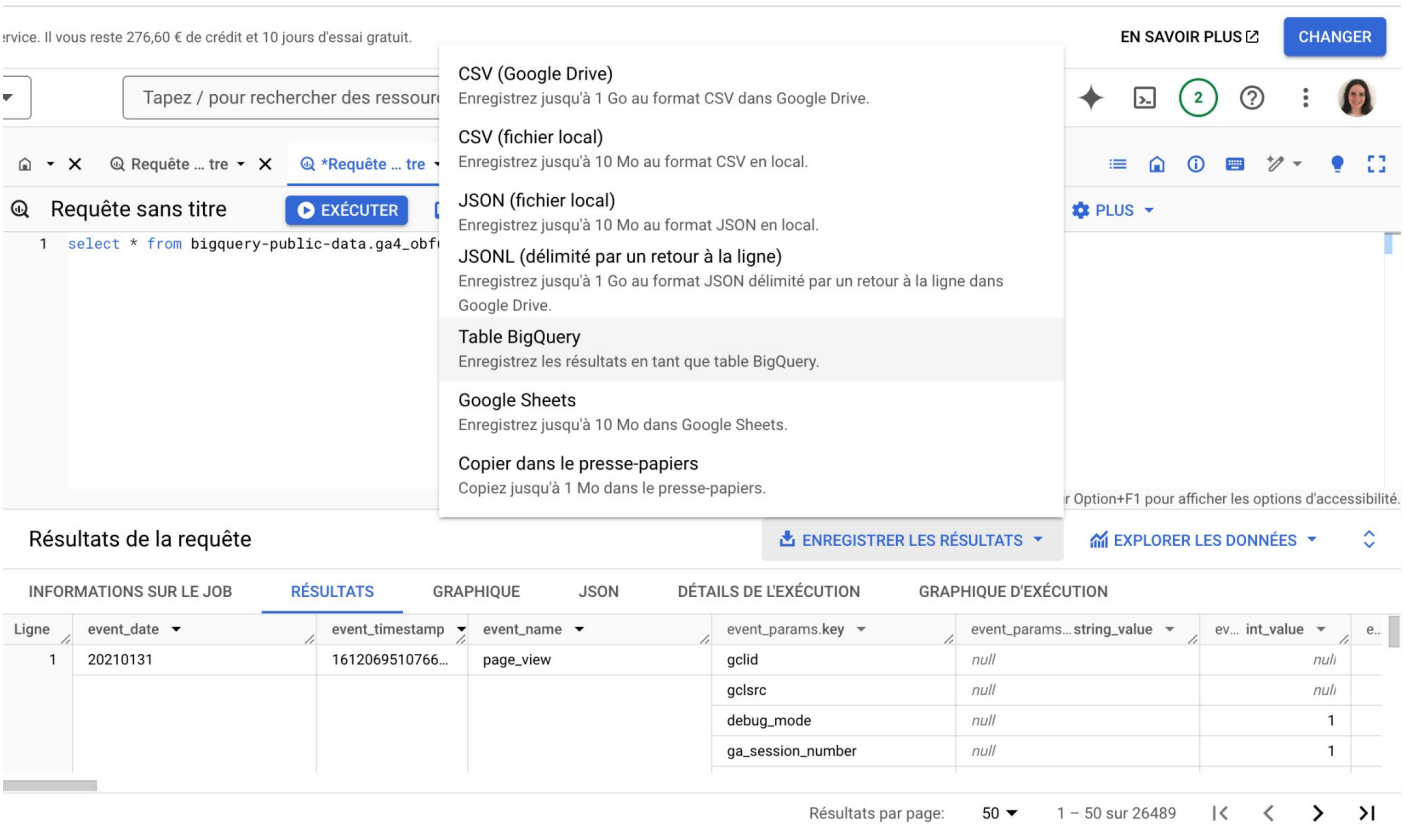

- Créer un schéma google_analytics_4 et mettre la table events dedans avec comme nom events_20210131

Une fois les données GA4 chargées, nous pouvons commencer la modélisation en SQL :

Les données brutes de GA4 sont structurées d'une manière spécifique. En tant qu'Analytics Engineer, vous serez très probablement amenés à travailler avec ce type de structure, car elle est couramment utilisée et moderne.

Dans certaines colonnes, les données sont **imbriquées** (nested), c'est-à-dire qu'une seule colonne peut contenir des sous-structures complexes comme des objets ou des listes. Pour exploiter pleinement ces données, il est nécessaire de les "aplatir" (flatten), c'est-à-dire extraire ces sous-structures en colonnes distinctes.

Il est normal de ne pas savoir immédiatement comment exploiter ce type de table. Pour vous aider, nous vous fournissons des liens vers des documentations explicatives.

DataBird 2024 ©copyright

Suivez l'une de ces documentations :

- Comment démystifier les données GA4 : aplatir les structures imbriquées dans BigQuery.
- L'art d' "unnester" des requêtes SQL

Ensuite, écrivez une requête SQL qui aplatit la table et génère une table avec les colonnes suivantes sur une seule ligne :

- event_date
- event_timestamp
- ga_session_id (event_params)
- page_title
- page_location
- user_pseudo_id
- user_first_touch_timestamp
- browser
- traffic_source.medium
- traffic_source.source
- traffic_source.name

Enregistrez les résultats de la requête aplatie dans le schéma google_analytics_4 sous la table nommée event_flattened.

Partie 2 : Ajout d'un Cluster

Avec quelle(s) colonne(s) serait-il pertinent de créer un cluster pour la table event_flattened que nous venons d'enregistrer dans BigQuery ?

Pour choisir un bon cluster, sélectionnez des colonnes qui apparaissent fréquemment dans les clauses **WHERE**, **JOIN**, ou **GROUP BY**.

Il est important de privilégier des colonnes ayant une diversité de valeurs modérée (ni trop unique ni trop répétée) afin d'optimiser l'efficacité du clustering.

Utilisez la commande **DDL suivante** pour créer la version clusterisée de la table event_flattened.

DataBird 2024 ©copyright

```
CREATE TABLE …
CLUSTER BY … AS
SELECT …
FROM …;
```

Partie 3 : Création de la table google_analytics_4.session

Dans Google Analytics 4 (GA4), les données sont structurées **au niveau des événements (event-level)**, ce qui signifie que chaque enregistrement correspond à une action spécifique effectuée par un utilisateur (par exemple, un clic, une page vue, etc.).
Cependant, il est souvent utile de regrouper ces événements pour analyser les **sessions**, c'est-à-dire un ensemble d'événements liés qui se produisent pendant une interaction continue d'un utilisateur avec un site web.

Écrivez une requête SQL **au niveau de la session (session-level)** qui se base sur la table `google_analytics.event_flattened` pour agréger les données initialement **au niveau des événements (event-level)** et les regrouper a**u niveau des sessions (session-level)**.

Dans notre requêtes, nous souhaitons les colonnes suivantes en résultats :

- user_pseudo_id
- ga_session_id
- unique_session_id (*)
- Session_start_time (timestamp de début de la session)
- session_end_time
- session_duration_seconds
- pages_viewed (nombre d'événements page_view pendant la session)
- event_count
- browser_used
- traffic_medium
- traffic_source
- traffic_name

DataBird 2024 ©copyright

Indications :

* La colonne ga_session_id représente une session, mais il est possible que deux utilisateurs aient le même ga_session_id par hasard.
Il est donc nécessaire de créer une colonne "unique_session_id" qui assure l'unicité de chaque session pour chaque utilisateur.

Exercice 3

Set up d'un nouveau connecteur

Fivetran offre un connecteur avec Gmail que nous allons tester dans cet exercice. Ce connecteur vous permet de récupérer toutes les données concernant votre compte Gmail.

Set up un connecteur Fivetran avec votre compte Gmail en suivant la documentation de Fivetran step by step pour le set up.

Allez consulter la documentation du connecteur et notamment sur le schéma des tables disponibles ici → https://fivetran.com/docs/connectors/applications/gmail.

Quelle est la différence entre message et thread ?

Faire une requête SQL qui renvoie une table qui contient par jour le nombre de nouveaux :

- message
- thread
- messages qui sont dans inbox
- messages qui sont classés dans la catégorie important
- messages non lus
- threads non lus
- messages envoyés
- messages qui sont dans les spams
- messages qui sont classés dans la catégorie promotions

DataBird 2024 ©copyright

Aller vérifier vos résultats dans Gmail, en filtrant dans votre barre de recherche.

Une fois la requête exécutée, retourner dans Fivetran et exclure du schéma de base, toutes les tables et colonnes de Gmail qui ne sont pas utilisées dans la requête pour optimiser les coûts.

Exercice 4

Optimisation des connecteurs

Fivetran offre généralement une période d'essai gratuite de 14 jours pour ses connecteurs, permettant à l'utilisateur de synchroniser ses données sans frais (les coûts de stockage dans la destination restent à la charge de l'utilisateur).

Expliquez à quoi cette période d'essai peut servir concrètement pour une entreprise.
Donnez des exemples précis montrant comment une entreprise pourrait tirer parti de cette période pour évaluer l'intégration de Fivetran dans ses processus.
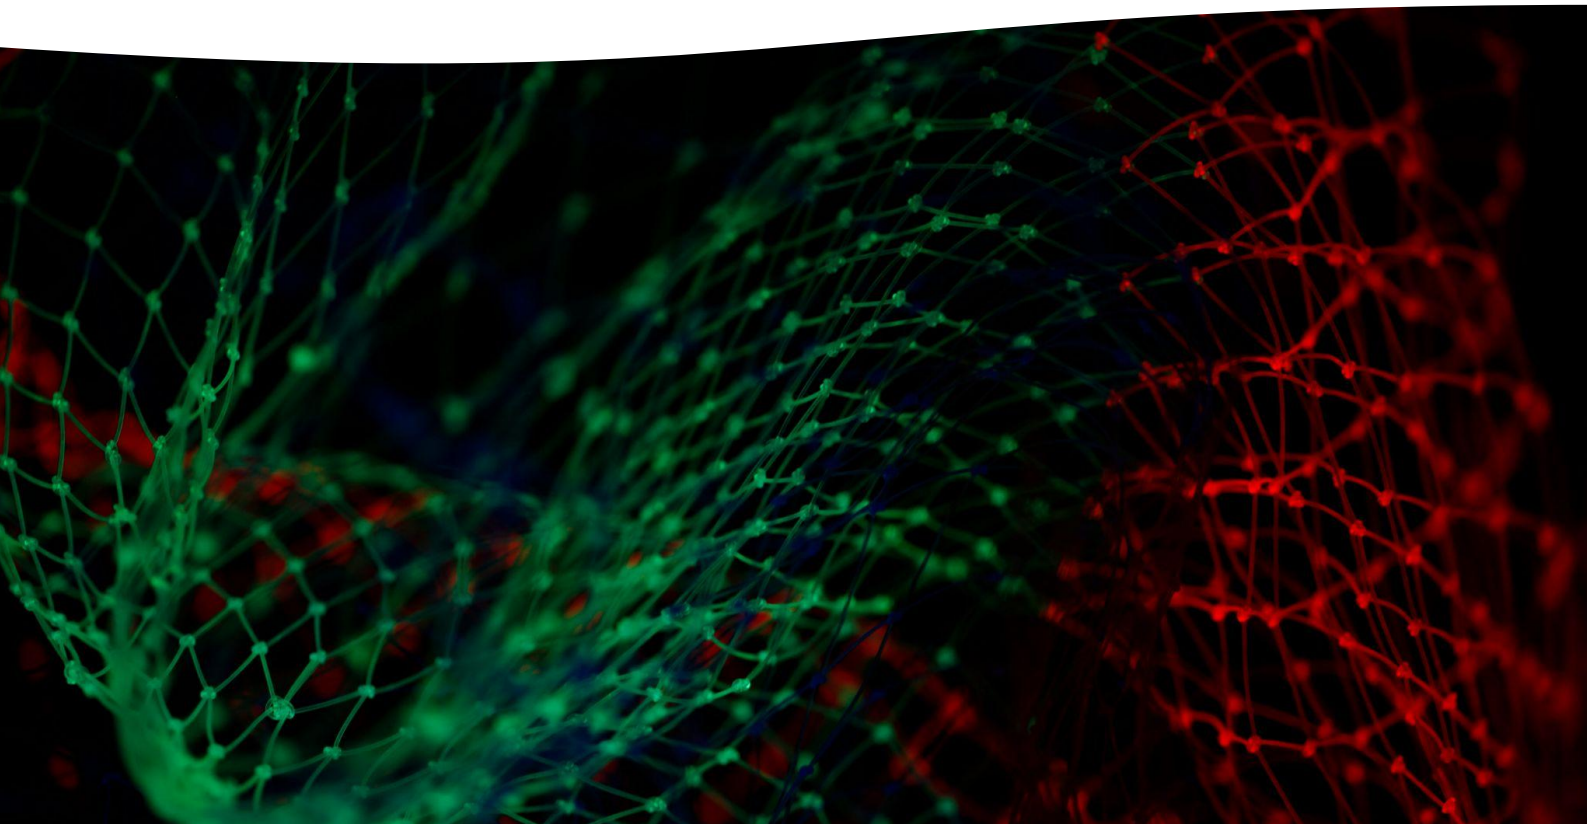
Sachant que Fivetran facture ses clients en fonction du nombre de lignes actualisées (MAR = monthly active rows).
Quelles solutions voyez-vous pour optimiser le MAR des entreprises ?